

**ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ**



**XÂY DỰNG MÔ HÌNH MẠNG NƠ-RON TÍCH
CHẬP PHỤC VỤ PHÂN LOẠI CẢM XÚC**

**BÁO CÁO BÀI TẬP CUỐI KỲ
CƠ SỞ TRÍ TUỆ NHÂN TẠO**

Giảng viên hướng dẫn: PGS.TS Hoàng Văn Xiêm

**Sinh viên thực hiện: Đình Văn Phúc - 23020756
Bùi Mạnh Dũng - 23020728
Nguyễn Sinh Hùng - 23021831**

HÀ NỘI – 2025

Tóm tắt nội dung

Phân loại cảm xúc là một bài toán quan trọng trong lĩnh vực trí tuệ nhân tạo, đặc biệt trong các ứng dụng tương tác người – máy và phân tích dữ liệu người dùng. Báo cáo này trình bày quá trình xây dựng và đánh giá một mô hình mạng nơ-ron tích chập (CNN) nhằm phân loại cảm xúc. Mô hình được huấn luyện và kiểm tra trên bộ dữ liệu chuẩn FER2013. Kết quả thực nghiệm cho thấy mô hình có thể phân loại được một số cảm xúc cơ bản, phù hợp với khuôn khổ môn học. Tuy vậy, mô hình vẫn cần bổ sung và tối ưu hơn để đưa vào thực tế.

I. Giới thiệu bài toán

1.1 Bối cảnh và tổng quan

Phân loại cảm xúc đóng vai trò quan trọng trong nhiều lĩnh vực như xử lý ngôn ngữ tự nhiên, thị giác máy tính và tương tác người – máy. Các ứng dụng tiêu biểu bao gồm phân tích cảm xúc trên mạng xã hội, hệ thống chăm sóc khách hàng tự động và các trợ lý ảo thông minh.

Sự phát triển mạnh mẽ của học sâu, đặc biệt là mạng nơ-ron tích chập, đã mang lại những bước tiến đáng kể trong các bài toán nhận dạng mẫu và phân loại dữ liệu phức tạp.

Các phương pháp truyền thống trong phân loại cảm xúc thường dựa trên đặc trưng thủ công kết hợp với các thuật toán học máy cổ điển như máy véc-tơ hỗ trợ, k-lân cận gần nhất hoặc Naive Bayes. Tuy nhiên, các phương pháp này gặp hạn chế trong việc trích xuất đặc trưng cấp cao.

Các mô hình học máy đã giải quyết được nhiều bài toán phức tạp trong nhiều lĩnh vực khác nhau. Tuy nhiên, trong trường hợp cụ thể này, các kỹ thuật học máy truyền thống là chưa đủ để phát hiện cảm xúc một cách chính xác. Để giải quyết vấn đề đó, một mô hình học sâu đã được phát triển nhằm hỗ trợ phân loại cảm xúc một cách nhanh chóng, chính xác và theo thời gian thực. Mô hình đề xuất dựa trên mạng nơ-ron tích chập (CNN), có khả năng trích xuất đặc trưng từ hình ảnh và phân loại các cảm xúc dựa trên các mẫu đã học.

Học sâu (Deep Learning) là một nhánh của Học máy (Machine Learning) dùng mạng nơ-ron nhiều tầng để mô phỏng quá trình ra quyết định phức tạp như con người. Khác với học máy truyền thống (thường ít tầng ẩn), học sâu có nhiều tầng hơn nên học và trích xuất được đặc trưng phức tạp từ dữ liệu lớn. Học sâu được phát triển mạnh vì mô hình truyền thống gặp hạn chế khi xử lý dữ liệu phức tạp; học sâu giải quyết tốt các bài toán như sinh văn bản, dịch máy, tương tác người-máy và tạo nội dung.

Ứng dụng học sâu xuất hiện rộng rãi: thị giác máy tính (nhận dạng ảnh, phát hiện khuôn mặt/đối tượng), xử lý ngôn ngữ tự nhiên (dịch, chatbot, phân tích cảm xúc, tóm tắt), xe tự hành (nhận biết môi trường và ra quyết định điều hướng).

Trong NLP, các mô hình hiện đại (LLMs) hiểu ngữ cảnh và quan hệ ngữ nghĩa, làm được nhiều tác vụ phức tạp như sinh văn bản, tóm tắt, dịch, trả lời câu hỏi.

Một số mô hình/kiến trúc NLP tiêu biểu: RNN, LSTM, Transformer (self-attention), BERT, GPT. Trong Computer Vision, học sâu chủ đạo dựa trên CNN; các mô hình tiêu biểu gồm CNN, ResNet, YOLO và U-Net (thường dùng cho phân đoạn ảnh, nhất là ảnh y tế).

1.2 Mục tiêu của đề tài

Mục tiêu của đề tài này là xây dựng, huấn luyện và đánh giá một mô hình mạng nơ-ron tích chập (Convolutional Neural Network – CNN) nhằm giải quyết bài toán phân loại cảm xúc khuôn mặt dựa trên bộ dữ liệu FER2013.

Thông qua đề tài, sinh viên hướng tới việc nắm vững quy trình xây dựng một mô hình học sâu hoàn chỉnh, bao gồm các bước từ tiền xử lý dữ liệu, thiết kế kiến trúc mạng, huấn luyện mô hình cho đến đánh giá và phân tích kết quả thực nghiệm.

Cụ thể, các mục tiêu chính bao gồm:

- Xây dựng mô hình CNN phù hợp với dữ liệu ảnh xám kích thước nhỏ (48×48 pixel).

- Áp dụng các kỹ thuật tiền xử lý và tăng cường dữ liệu nhằm cải thiện khả năng tổng quát hóa.
- Huấn luyện mô hình và đánh giá hiệu quả thông qua các chỉ số định lượng.
- Phân tích ưu điểm, hạn chế của mô hình và đề xuất hướng phát triển trong tương lai.

1.3 Định hướng giải quyết bài toán

Để đạt được các mục tiêu đề ra, đề tài được triển khai theo các định hướng sau. Trước hết, bộ dữ liệu FER2013 được lựa chọn làm tập dữ liệu chính do đây là bộ dữ liệu tiêu chuẩn, phổ biến trong các nghiên cứu nhận dạng cảm xúc khuôn mặt.

Tiếp theo, mô hình CNN được thiết kế theo hướng cân bằng giữa độ chính xác và chi phí tính toán, phù hợp với điều kiện thực nghiệm của sinh viên. Các kỹ thuật chuẩn hóa batch và dropout được sử dụng nhằm hạn chế hiện tượng quá khớp.

Cuối cùng, mô hình được huấn luyện, đánh giá và phân tích kết quả dựa trên các chỉ số định lượng, từ đó rút ra nhận xét về hiệu quả và khả năng ứng dụng của mô hình.

II. Phương pháp thực hiện

2.1 Tiền xử lý và chuẩn bị dữ liệu

Bộ dữ liệu FER2013 bao gồm các ảnh khuôn mặt xám với kích thước 48×48 pixel. Trong nghiên cứu này, dữ liệu được tiền xử lý theo các bước sau:

- Chuẩn hóa giá trị pixel bằng cách chia cho 255 để đưa dữ liệu về khoảng $[0, 1]$.
- Chuyển ảnh về chế độ ảnh xám nhằm giảm số kênh đầu vào và chi phí tính toán.
- Đảm bảo kích thước ảnh đầu vào là 48×48 pixel.
- Áp dụng kỹ thuật tăng cường dữ liệu như xoay ảnh, phóng to/thu nhỏ và lật ngang nhằm tăng tính đa dạng của tập huấn luyện.

Các bước tăng cường dữ liệu được thực hiện thông qua lớp ImageDataGenerator của thư viện TensorFlow/Keras.

2.2 Cấu trúc mô hình

Mô hình được xây dựng dựa trên mạng nơ-ron tích chập sâu (Convolutional Neural Network – CNN) nhằm phân loại cảm xúc từ ảnh khuôn mặt xám có kích thước 48×48 . Kiến trúc gồm ba khối tích chập chính (Convolutional Blocks) và một bộ phân loại (Classifier).

Ảnh đầu vào được biểu diễn dưới dạng tensor:

$$\mathbf{X} \in R^{48 \times 48 \times 1}$$

Trong đó, chiều thứ ba biểu thị kênh màu xám.

Lớp tích chập (Convolutional Layer)

Lớp tích chập sử dụng các kernel kích thước 3×3 , stride bằng 1 và padding “same” nhằm bảo toàn kích thước không gian của ảnh.

Giá trị tại vị trí (i, j) của feature map thứ k được tính theo công thức:

$$z_{i,j}^{(k)} = \sum_{c=1}^C \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} W_{m,n,c}^{(k)} \cdot X_{i+m,j+n,c} + b^{(k)}$$

Trong đó:

- $W^{(k)}$ là kernel thứ k
- $b^{(k)}$ là hệ số bias
- C là số kênh đầu vào

Sau đó, hàm kích hoạt ReLU được áp dụng:

$$a_{i,j}^{(k)} = \max(0, z_{i,j}^{(k)})$$

Chuẩn hóa theo batch (Batch Normalization)

Batch Normalization được sử dụng để ổn định và tăng tốc quá trình huấn luyện. Với mỗi mini-batch, đầu vào được chuẩn hóa theo:

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

Sau đó được biến đổi tuyến tính:

$$y = \gamma \hat{x} + \beta$$

Trong đó:

- μ_B, σ_B^2 là trung bình và phương sai của batch
- γ, β là các tham số học được

Lớp gộp cực đại (Max Pooling)

Lớp Max Pooling với kích thước 2×2 được sử dụng nhằm giảm kích thước không gian và số lượng tham số.

Phép toán được định nghĩa:

$$y_{i,j}^{(k)} = \max_{0 \leq m,n < 2} x_{2i+m, 2j+n}^{(k)}$$


Global Average Pooling

Thay vì sử dụng lớp Flatten truyền thống, mô hình áp dụng Global Average Pooling nhằm giảm số lượng tham số. Với feature map kích thước $H \times W$, đầu ra được xác định bằng:

$$g_k = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W a_{i,j}^{(k)}$$

Lớp Dropout

Dropout là kỹ thuật trong đó một phần các nút ẩn (thường là 50%) sẽ được đặt thành 0 một cách ngẫu nhiên tại mỗi lần lặp trong quá trình tối ưu bằng stochastic gradient descent (SGD). Điều này giúp mô hình không phụ thuộc quá mức vào bất kỳ một nút ẩn cụ thể nào và khuyến khích các trọng số giữ giá trị nhỏ, qua đó giảm độ nhạy của mạng đối với sự có mặt hoặc vắng mặt của một số đơn vị nhất định.



Hình 1: Dropout: a) Mạng ban đầu b) Một tập con ngẫu nhiên các nút ẩn bị đặt về 0 (các nút màu xám)

Lớp kết nối đầy đủ (Fully Connected Layer)

Vector đặc trưng sau Global Average Pooling được đưa qua lớp Dense với hàm kích hoạt ReLU:

$$h = \max(0, W_g g + b_g)$$

Lớp Softmax và phân loại

Lớp cuối cùng sử dụng hàm Softmax để phân loại ảnh vào 7 nhãn cảm xúc.

$$P(y = k | x) = \frac{e^{z_k}}{\sum_{i=1}^7 e^{z_i}}$$

Trong đó $P(y = k|x)$ là xác suất ảnh thuộc cảm xúc thứ k

Hàm mất mát (Loss Function)


Mô hình được huấn luyện bằng hàm mất mát Categorical Cross-Entropy:

$$\mathcal{L} = - \sum_{k=1}^7 y_k \log(\hat{y}_k)$$

Trong đó:

- y_k là nhãn thực
- $\hat{y}_k$ là xác suất dự đoán

Cấu trúc mạng CNN được thiết kế và trực quan:



Hình 2: Emotion Classification CNN Model

2.3 Huấn luyện mô hình


Mô hình được huấn luyện với các thiết lập sau:

- Thuật toán tối ưu: Adam.
- Hàm mất mát: Categorical Cross-Entropy.
- Kích thước batch: 64.
- Số epoch huấn luyện: 30.

Trong quá trình huấn luyện, mô hình được đánh giá trên tập kiểm tra sau mỗi epoch nhằm theo dõi sự thay đổi của độ chính xác và giá trị hàm mất mát. Kết quả huấn luyện được trực quan hóa thông qua các biểu đồ accuracy và loss theo số epoch.

Epoch 9/30	
449/449	27s 60ms/step - accuracy: 0.5927 - loss: 1.0930 - val_accuracy: 0.5605 - val_loss: 1.1480
Epoch 10/30	
449/449	26s 58ms/step - accuracy: 0.5929 - loss: 1.0914 - val_accuracy: 0.5819 - val_loss: 1.1370
Epoch 11/30	
449/449	27s 59ms/step - accuracy: 0.6015 - loss: 1.0604 - val_accuracy: 0.6127 - val_loss: 1.0439
Epoch 12/30	
449/449	27s 60ms/step - accuracy: 0.6097 - loss: 1.0465 - val_accuracy: 0.6257 - val_loss: 0.9986
Epoch 13/30	
449/449	40s 58ms/step - accuracy: 0.6175 - loss: 1.0268 - val_accuracy: 0.6031 - val_loss: 1.0706
Epoch 14/30	
449/449	27s 59ms/step - accuracy: 0.6223 - loss: 1.0133 - val_accuracy: 0.6007 - val_loss: 1.0708
Epoch 15/30	
449/449	26s 59ms/step - accuracy: 0.6314 - loss: 0.9957 - val_accuracy: 0.6360 - val_loss: 0.9918
Epoch 16/30	
449/449	26s 58ms/step - accuracy: 0.6343 - loss: 0.9782 - val_accuracy: 0.6390 - val_loss: 0.9678
Epoch 17/30	
449/449	26s 58ms/step - accuracy: 0.6347 - loss: 0.9681 - val_accuracy: 0.6293 - val_loss: 1.0105
Epoch 18/30	
449/449	28s 61ms/step - accuracy: 0.6377 - loss: 0.9645 - val_accuracy: 0.6276 - val_loss: 1.0014
Epoch 19/30	
449/449	26s 58ms/step - accuracy: 0.6415 - loss: 0.9550 - val_accuracy: 0.6429 - val_loss: 0.9621
Epoch 20/30	
449/449	26s 58ms/step - accuracy: 0.6443 - loss: 0.9420 - val_accuracy: 0.6414 - val_loss: 0.9485
Epoch 21/30	
449/449	26s 58ms/step - accuracy: 0.6532 - loss: 0.9335 - val_accuracy: 0.6403 - val_loss: 0.9672
Epoch 22/30	
449/449	26s 58ms/step - accuracy: 0.6545 - loss: 0.9266 - val_accuracy: 0.6477 - val_loss: 0.9521
Epoch 23/30	
449/449	26s 58ms/step - accuracy: 0.6579 - loss: 0.9157 - val_accuracy: 0.6425 - val_loss: 0.9479
Epoch 24/30	
449/449	26s 57ms/step - accuracy: 0.6646 - loss: 0.9099 - val_accuracy: 0.6486 - val_loss: 0.9422
Epoch 25/30	
449/449	26s 57ms/step - accuracy: 0.6665 - loss: 0.8924 - val_accuracy: 0.6351 - val_loss: 0.9801
Epoch 26/30	
449/449	26s 58ms/step - accuracy: 0.6643 - loss: 0.8915 - val_accuracy: 0.6399 - val_loss: 0.9819
Epoch 27/30	
449/449	26s 58ms/step - accuracy: 0.6686 - loss: 0.8832 - val_accuracy: 0.6516 - val_loss: 0.9490
Epoch 28/30	
449/449	26s 57ms/step - accuracy: 0.6749 - loss: 0.8826 - val_accuracy: 0.6456 - val_loss: 0.9529
Epoch 29/30	
449/449	25s 55ms/step - accuracy: 0.6686 - loss: 0.8852 - val_accuracy: 0.6584 - val_loss: 0.9258
Epoch 30/30	
449/449	25s 56ms/step - accuracy: 0.6812 - loss: 0.8632 - val_accuracy: 0.6513 - val_loss: 0.9544

Hình 3: Training per epoch




Hình 4: Accuracy and Loss per epoch

III. Kết quả

3.1 Kết quả đánh giá tập validation


Sau khi hoàn tất quá trình huấn luyện, mô hình mạng nơ-ron tích chập được lưu lại các trọng số và tiến hành đánh giá hiệu năng trên tập dữ liệu kiểm tra. Mục tiêu của bước này là kiểm tra khả năng dự đoán tập dữ liệu đã được đưa vào trong quá trình training để đóng vai trò tham chiếu.



Hình 5: Kết quả dự đoán trên tập dữ liệu validation

3.2 Kết quả đánh giá trên dữ liệu ngoài

Sau khi hoàn tất quá trình huấn luyện, mô hình mạng nơ-ron tích chập được lưu lại các trọng số tốt nhất và tiến hành đánh giá hiệu năng trên tập dữ liệu kiểm tra độc lập. Mục tiêu của bước đánh giá này là kiểm tra khả năng tổng quát hóa của mô hình khi xử lý các ảnh khuôn mặt chưa từng xuất hiện trong quá trình huấn luyện và validation.




Hình 6: Kết quả phân loại cảm xúc trên tập dữ liệu kiểm tra

3.3 Đánh giá mô hình

Thông qua quá trình huấn luyện và thử nghiệm, mô hình mạng nơ-ron tích chập (CNN) được xây dựng đã đạt được kết quả phân loại tương đối tốt, thể hiện qua tỷ lệ dự đoán chính xác cao trên tập dữ liệu kiểm thử. Điều này cho thấy kiến trúc mô hình cùng với quá trình huấn luyện là phù hợp với bài toán phân loại cảm xúc khuôn mặt.

Có thể quan sát trên Confusion Matrix và thấy rằng mô hình có xu hướng dự đoán mạnh vào hai lớp *happy* và *neutral*, thể hiện qua các giá trị lớn tập trung tại hai cột tương ứng. Nhiều mẫu thuộc các lớp khác như *angry*, *fear*, *sad* và *surprise* bị nhầm lẫn và phân loại sai sang hai lớp này.

Đặc biệt, lớp *disgust* cho thấy hiệu năng nhận diện rất thấp với số lượng dự đoán đúng gần như không đáng kể. Nguyên nhân có thể đến từ sự mất cân bằng dữ liệu giữa



Hình 7: Confusion matrix

các lớp, khi số lượng mẫu của lớp disgust thấp hơn đáng kể so với các lớp còn lại, cũng như sự chồng lấn đặc trưng biểu cảm khuôn mặt giữa các cảm xúc.

Kết quả này cho thấy mô hình chưa học được các đặc trưng phân biệt mạnh mẽ đối với các cảm xúc khó, đồng thời phản ánh hiện tượng mất cân bằng dữ liệu về các lớp có số lượng mẫu lớn và đặc trưng rõ ràng hơn. Do đó, mặc dù mô hình đạt được một mức độ chính xác nhất định, hiệu năng tổng thể vẫn còn hạn chế và cần được cải thiện thông qua các kỹ thuật như cân bằng dữ liệu, điều chỉnh hàm mất mát hoặc sử dụng các mô hình học sâu tiên tiến hơn.

Cụ thể, đối với những ảnh đầu vào có nhiều điểm ảnh nhiễu, ánh sáng không đồng đều, hoặc chứa nhiều chi tiết thừa ở vùng nền, mô hình có xu hướng dự đoán sai nhãn cảm xúc. Ngược lại, khi ảnh được chụp ở khoảng cách gần hơn, khuôn mặt chiếm phần lớn khung hình và ít nhiễu nền, mô hình cho kết quả dự đoán chính xác và ổn định hơn.

Từ hiện tượng trên có thể nhận thấy rằng mô hình CNN nhạy cảm với chất lượng và mức độ tập trung của ảnh đầu vào, đặc biệt là trong trường hợp khuôn mặt không được làm nổi bật rõ ràng so với nền. Điều này cho thấy mô hình hiện tại chưa hoàn toàn mạnh trong việc khái quát hóa (generalization) đối với các điều kiện ảnh phức tạp ngoài môi trường huấn luyện.

Mặc dù vậy, kết quả đạt được vẫn cho thấy mô hình có tiềm năng ứng dụng thực tế, đặc biệt trong các điều kiện đầu vào được kiểm soát tốt. Trong các nghiên cứu và phát triển tiếp theo, mô hình có thể được cải thiện thông qua việc tiền xử lý ảnh tốt hơn, tăng cường dữ liệu (data augmentation) hoặc sử dụng các kỹ thuật loại bỏ nhiễu, nhằm nâng cao khả năng nhận diện cảm xúc trong những tình huống thực tế đa dạng hơn.

IV. Thảo luận

Kết quả thực nghiệm cho thấy mô hình mạng nơ-ron tích chập (CNN) đã học được một số đặc trưng cơ bản của khuôn mặt người và có khả năng phân loại cảm xúc ở mức độ nhất định. Việc sử dụng các kỹ thuật như batch normalization và dropout góp phần cải thiện tính ổn định của quá trình huấn luyện, đồng thời hạn chế hiện tượng quá khớp trên tập dữ liệu huấn luyện.

Tuy nhiên, hiệu năng tổng thể của mô hình trên tập validation vẫn còn hạn chế, đặc biệt trong việc phân biệt các cảm xúc có biểu hiện khuôn mặt tương đồng như *fear* và *surprise*, hoặc *sad* và *neutral*. Phân tích ma trận nhầm lẫn cho thấy mô hình có xu hướng thiên lệch trong dự đoán về các lớp *happy* và *neutral*, trong khi các lớp có số lượng mẫu ít hơn, điển hình là *disgust*, đạt độ chính xác rất thấp.

Nguyên nhân chính của hiện tượng này đến từ sự mất cân bằng dữ liệu trong bộ FER2013, cùng với chất lượng ảnh đầu vào còn hạn chế, bao gồm độ phân giải thấp và nhiễu trong biểu cảm khuôn mặt. Bên cạnh đó, kiến trúc CNN được sử dụng vẫn còn tương đối đơn giản, chưa đủ khả năng trích xuất các đặc trưng phân biệt mạnh mẽ đối với các cảm xúc phức tạp.

Trong các nghiên cứu tiếp theo, hiệu năng của mô hình có thể được cải thiện bằng cách áp dụng các kỹ thuật cân bằng dữ liệu, sử dụng hàm mất mát phù hợp cho dữ liệu không cân bằng, hoặc khai thác các mô hình học sâu tiên tiến hơn.

V. Kết luận

Trong báo cáo này, mô hình mạng nơ-ron tích chập (CNN) đã được xây dựng và huấn luyện thành công để giải quyết bài toán phân loại cảm xúc khuôn mặt dựa trên bộ dữ liệu FER2013. Kết quả thực nghiệm cho thấy mô hình có khả năng phân loại cảm xúc với độ chính xác tương đối tốt, đạt được các mục tiêu nghiên cứu đề ra và có tiềm năng ứng dụng trong thực tế. Việc sử dụng các kỹ thuật như batch normalization và dropout đã giúp cải thiện độ ổn định trong quá trình huấn luyện, từ đó nâng cao hiệu quả mô hình. Tuy nhiên, mô hình vẫn gặp phải một số hạn chế, đặc biệt khi xử lý các cảm xúc có biểu hiện tương đồng hoặc khi ảnh đầu vào có chất lượng thấp hoặc chứa nhiễu.

VI. Hướng phát triển trong tương lai

Trong tương lai, nghiên cứu có thể được mở rộng theo các hướng sau:

- Áp dụng các kiến trúc học sâu hơn: Các mô hình học sâu như VGG hoặc ResNet có thể được thử nghiệm để cải thiện khả năng trích xuất đặc trưng và độ chính xác của mô hình.
- Sử dụng các kỹ thuật xử lý dữ liệu mất cân bằng: Các phương pháp như oversampling, undersampling, hoặc hàm mất mát nâng cao có thể giúp giải quyết vấn đề mất cân bằng dữ liệu trong bộ FER2013, từ đó cải thiện hiệu quả phân loại.

- Tăng độ phân giải ảnh đầu vào: Việc sử dụng ảnh có độ phân giải cao hơn có thể giúp mô hình học được các đặc trưng chi tiết hơn, đặc biệt là khi khuôn mặt trong ảnh không đủ rõ nét.
- Phát triển hệ thống nhận dạng cảm xúc thời gian thực: Nghiên cứu có thể mở rộng để phát triển một hệ thống nhận dạng cảm xúc từ video hoặc webcam, hỗ trợ nhận diện cảm xúc thời gian thực, phù hợp với các ứng dụng trong các môi trường tương tác người – máy như trợ lý ảo hay chăm sóc khách hàng tự động.